

Clasificación de COVID-19 a partir del sonido de la tos mediante características MFCC y modelos clásicos de aprendizaje automático

Roger Reátegui Soto

Maestría en DS/AI

Universidad de Ingeniería y Tecnología (UTEC)
Lima, Perú

Erick Rosas Pisfil

Maestría en DS/AI

Universidad de Ingeniería y Tecnología (UTEC)
Lima, Perú

Yemar Puma Huamán

Maestría en DS/AI

Universidad de Ingeniería y Tecnología (UTEC)
Lima, Perú

Resumen—Este trabajo aborda la clasificación de pacientes como COVID-19 positivos o negativos empleando únicamente el sonido de su tos. A partir de las colecciones COSWARA y Virufy, con 1207 toses negativas y 150 positivas, cada grabación se representa con coeficientes cepstrales en las frecuencias de Mel (MFCC), resumidos mediante su media y desviación estándar. Se comparan cuatro modelos clásicos (Regresión Logística, Máquinas de Vectores de Soporte, Árbol de Decisión y K vecinos más cercanos) y, adicionalmente, Random Forest, entrenados con validación cruzada de cinco particiones a nivel de paciente para evitar la fuga de datos. Dado el fuerte desbalance de clases (89/11), la evaluación prioriza el F1 y el recall de la clase positiva. El mejor modelo fue una SVM con kernel RBF. Se estudiaron varias estrategias de mejora; el ajuste del umbral de decisión resultó la más efectiva, elevando el recall de positivos de 0.42 a 0.50 y la exactitud balanceada de 0.69 a 0.72 en el conjunto de prueba, con una pérdida mínima de exactitud global.

Index Terms—COVID-19, clasificación de audio, MFCC, SVM, clases desbalanceadas, validación cruzada

I. INTRODUCCIÓN

La detección temprana y de bajo costo de infecciones respiratorias es un problema de gran interés. La tos es un síntoma frecuente de la COVID-19 y puede registrarse con un simple micrófono, lo que motiva el estudio de sistemas capaces de estimar el riesgo a partir de su sonido. El objetivo de este proyecto es clasificar pacientes como positivos o negativos usando exclusivamente el audio de la tos, aplicando los modelos de clasificación vistos en el curso.

Las contribuciones de este trabajo son: (i) un flujo de preprocesamiento y extracción de características basado en MFCC; (ii) una comparación sistemática de cinco clasificadores mediante validación cruzada a nivel de paciente; y (iii) un análisis de estrategias para mejorar la detección de la clase minoritaria, que es la de mayor interés clínico. El código y los resultados son reproducibles y están disponibles en el

repositorio del proyecto¹, con una semilla fija.

II. CONJUNTO DE DATOS

El conjunto de datos se construye a partir de muestras de las colecciones COSWARA [1] y Virufy [2]. Contiene 1207 toses de personas con prueba negativa y 150 de personas positivas. La clase positiva mezcla dos formatos: 102 archivos .wav y 48 .mp3, todos conservados. Existe además una carpeta Unknown sin etiqueta, que se descarta por no aportar a la medición de métricas.

El conjunto presenta un fuerte desbalance: aproximadamente 89 % de ejemplos negativos frente a 11 % positivos (Fig. 1). Este desbalance condiciona toda la evaluación, ya que un clasificador que prediga siempre la clase negativa alcanzaría cerca de 89 % de exactitud sin detectar ningún caso de COVID-19.

Durante la revisión se identificaron varios detalles de calidad de datos. La etiqueta se toma de la carpeta y no del nombre del archivo, pues nueve archivos presentan el error tipográfico *Postive*. La edad y el género, incluidos en el nombre de cada archivo, se conservan solo como metadatos descriptivos y no se usan como características, ya que el objetivo es clasificar únicamente con el sonido. Finalmente, cinco pacientes positivos aportan varias grabaciones (por ejemplo, un paciente aporta 22 audios); se verificó que son grabaciones distintas y no copias, por lo que se conservan, con la precaución descrita en la Sección III-B.

III. METODOLOGÍA

III-A. Extracción de características

Un audio en crudo es una señal larga y de duración variable (entre 2.5 y 26 segundos), por lo que no puede utilizarse directamente como entrada de los modelos. El enunciado

¹Código: <https://github.com/erosas-utec/ml-project-classification> — Demo web: <https://ml-project-classification.onrender.com>




Figura 1. Distribución de clases. El conjunto está fuertemente desbalanceado hacia la clase negativa.

permite emplear librerías para obtener el mejor vector de características; se utilizan los MFCC [3], que resumen el timbre del sonido en pocas dimensiones y son un estándar en el análisis de audio. La extracción se realiza con la librería *librosa* [4].

Para cada audio se calcula la matriz de 20 MFCC por ventana temporal y se resume con la media y la desviación estándar de cada coeficiente, obteniendo un vector fijo de 40 características, con independencia de la duración. Además, la carga remuestrea todas las señales a 22 050 Hz, lo que unifica los audios que llegan en 44.1 kHz y 48 kHz. Las características se almacenan en disco para garantizar la reproducibilidad sin necesidad de reprocesar el audio.

III-B. Partición y escalado

Se reserva el 20 % de los datos como conjunto de prueba, de forma estratificada y *a nivel de paciente*: primero se reparten los pacientes y luego se asignan sus grabaciones. Así, todas las grabaciones de un mismo paciente permanecen en el mismo subconjunto; de lo contrario, el modelo podría reconocer al paciente en la prueba y las métricas resultarían infladas por fuga de datos. El conjunto de entrenamiento resultante tiene 1067 audios (9.6 % positivos) y el de prueba 290 audios (16.6 % positivos). Las características se estandarizan con un *StandardScaler* ajustado únicamente con el entrenamiento.

III-C. Modelos

Se comparan los cuatro modelos solicitados y un método adicional, todos vistos en el curso: Regresión Logística, que aplica la función sigmoide sobre una combinación lineal de las características; SVM [6], que busca el hiperplano de máximo margen, empleando kernels lineal y RBF; Árbol de Decisión, que particiona el espacio reduciendo la impureza (Gini o entropía); K vecinos más cercanos (KNN), que clasifica por votación de los vecinos; y Random Forest, un ensamble por *bagging* de árboles, incluido como método adicional.

III-D. Validación y métricas

La selección de hiperparámetros se realiza sobre el entrenamiento mediante validación cruzada de cinco particiones

Tabla I
REGRESIÓN LOGÍSTICA

C	Acc	BAcc	Prec	Rec	F1
0.1	0.903	0.521	0.433	0.049	0.087
1.0	0.900	0.537	0.399	0.089	0.142
10	0.897	0.535	0.366	0.089	0.139

Tabla II
SVM (KERNEL Y MARGEN SUAVE C)

Kernel	C	Acc	BAcc	Prec	Rec	F1
lineal	0.1	0.904	0.500	0.000	0.000	0.000
lineal	1.0	0.904	0.500	0.000	0.000	0.000
lineal	10	0.904	0.500	0.000	0.000	0.000
RBF	0.1	0.904	0.500	0.000	0.000	0.000
RBF	1.0	0.910	0.530	0.800	0.060	0.110
RBF	10	0.905	0.615	0.522	0.255	0.339

con *StratifiedGroupKFold*: estratificada, para mantener la proporción de clases en cada partición, y agrupada, para que las grabaciones de un mismo paciente no se repartan entre particiones. Para cada configuración se reportan exactitud (Acc), exactitud balanceada (BAcc) y precisión (Prec), recall (Rec) y F1 de la clase positiva. Dado el desbalance, el F1 de la clase positiva es la métrica de selección [5].

IV. EXPERIMENTOS Y RESULTADOS

IV-A. Búsqueda de hiperparámetros

Las Tablas I–V presentan, para cada modelo, las métricas promedio de validación cruzada por cada configuración de hiperparámetros probada. Se observa un patrón común: casi todas las configuraciones alcanzan una exactitud alta (cerca a 0.90) que proviene de acertar en la clase mayoritaria, mientras que el recall de la clase positiva permanece bajo.

IV-B. Comparación entre modelos

La Fig. 2 compara la mejor configuración de cada modelo. El mejor F1 de la clase positiva lo obtiene la SVM con kernel RBF y $C = 10$ (F1 = 0.339, BAcc = 0.615), seguida de KNN (0.283) y el Árbol de Decisión (0.233). Es notable el caso de Random Forest: alcanza la mayor exactitud (0.908) pero un recall de apenas 0.04, es decir, casi no detecta positivos. Este contraste confirma que la exactitud no es una métrica adecuada bajo desbalance y justifica la elección del F1 de la clase positiva como criterio.

IV-C. Estrategias de mejora

Partiendo del mejor modelo (SVM RBF), se evaluaron cuatro estrategias, todas con la misma validación cruzada. La reducción de dimensionalidad con PCA (30 componentes que explican el 95 % de la varianza) y con LDA no mejoró el F1 (0.336 y 0.210, frente a 0.339 con los 40 MFCC). La ponderación de clases (*class_weight=balanced*) tampoco lo mejoró (0.322), como se resume en la Tabla VI, ni el uso de deltas de MFCC de primer y segundo orden (120 características, F1 = 0.233). Estas estrategias se documentan como exploración y no se incorporan al modelo final.

Tabla III
ÁRBOL DE DECISIÓN (CRITERIO Y PROFUNDIDAD)

Criterio	Prof.	Acc	BAcc	Prec	Rec	F1
Gini	3	0.900	0.511	0.167	0.030	0.051
Gini	5	0.895	0.548	0.344	0.118	0.172
Gini	10	0.868	0.555	0.218	0.169	0.190
Gini	–	0.858	0.581	0.229	0.238	0.233
Entrop.	3	0.899	0.527	0.333	0.068	0.100
Entrop.	5	0.879	0.552	0.283	0.147	0.192
Entrop.	10	0.850	0.567	0.216	0.216	0.214
Entrop.	–	0.839	0.569	0.203	0.236	0.218

Tabla IV
KNN (VECINOS K Y PONDERACIÓN)

K	Peso	Acc	BAcc	Prec	Rec	F1
3	uniforme	0.906	0.588	0.531	0.195	0.283
3	distancia	0.906	0.588	0.531	0.195	0.283
5	uniforme	0.913	0.570	0.730	0.147	0.242
5	distancia	0.914	0.575	0.750	0.157	0.256
7	uniforme	0.912	0.548	0.833	0.098	0.174
7	distancia	0.915	0.558	0.933	0.117	0.206
11	uniforme	0.907	0.515	0.600	0.029	0.055
11	distancia	0.908	0.520	0.800	0.039	0.074

La estrategia efectiva fue el ajuste del umbral de decisión. Los modelos probabilísticos deciden por defecto con el umbral 0.5; bajo desbalance, ese valor no es óptimo para detectar la clase minoritaria. Se obtuvieron las probabilidades fuera de muestra con validación cruzada y se seleccionó el umbral que maximiza el F1 de la clase positiva (Fig. 3), resultando en 0.25.

IV-D. Evaluación final en el conjunto de prueba

El modelo final (SVM RBF, $C = 10$, con umbral 0.25) se entrena con todo el conjunto de entrenamiento y se evalúa una única vez sobre el conjunto de prueba. La Tabla VII compara la línea base (umbral 0.5) con el modelo mejorado. El ajuste del umbral eleva el recall de positivos de 0.417 a 0.500, el F1 de 0.533 a 0.558 y la exactitud balanceada de 0.694 a 0.721, con una caída mínima de la exactitud global (de 0.879 a 0.869).

La matriz de confusión del modelo mejorado (Fig. 4) muestra que se detectan 24 de los 48 casos positivos (50.0 %) y se clasifican correctamente 228 de los 242 negativos (94.2 %). La exactitud total es de 0.869. El sistema es, por tanto, más útil para descartar la enfermedad que para confirmarla, lo cual es coherente con la dificultad de la tarea y con el uso exclusivo del sonido.

IV-E. Aplicación web de demostración

Para poner el modelo en práctica se desarrolló una aplicación web progresiva que permite grabar una tos desde el navegador y obtener una estimación en tiempo real. El servidor, implementado con FastAPI, reutiliza exactamente el mismo flujo de extracción de características (librosa) y el mismo modelo (scikit-learn) de los experimentos; por ello las características y las predicciones coinciden con las reportadas, sin desajuste entre el análisis y el despliegue (Fig. 5). La aplicación incorpora una comprobación de energía

Tabla V
RANDOM FOREST (ÁRBOLES Y PROFUNDIDAD)

Árboles	Prof.	Acc	BAcc	Prec	Rec	F1
100	5	0.906	0.510	0.400	0.020	0.038
100	10	0.906	0.514	0.400	0.030	0.055
100	–	0.907	0.519	0.600	0.040	0.074
200	5	0.906	0.510	0.400	0.020	0.038
200	10	0.907	0.515	0.400	0.030	0.055
200	–	0.908	0.520	0.600	0.040	0.074




Figura 2. Comparación de la mejor configuración de cada modelo (promedio de validación cruzada). La exactitud es alta en todos, pero el recall de la clase positiva es bajo.

que descarta grabaciones sin tos y, con consentimiento explícito del usuario, almacena las grabaciones de forma anónima para ampliar progresivamente el conjunto de datos, atendiendo a la principal limitación identificada: la escasez de ejemplos positivos. La herramienta es de carácter educativo y no constituye un diagnóstico; se encuentra disponible públicamente². La arquitectura completa del sistema y el pipeline detallado se documentan en línea³.

V. CONCLUSIONES

Se compararon cuatro modelos clásicos de clasificación, más Random Forest, para detectar COVID-19 a partir del sonido de la tos, empleando características MFCC y validación cruzada a nivel de paciente. El mejor modelo fue una SVM con kernel RBF. Se confirmó que, bajo un fuerte desbalance de clases, la exactitud es una métrica engañosa y que conviene guiarse por el F1 y el recall de la clase positiva.

De las estrategias de mejora estudiadas, la reducción de dimensionalidad, la ponderación de clases y los deltas de MFCC no aportaron mejoras en validación cruzada, mientras que el ajuste del umbral de decisión sí mejoró de forma consistente la detección de positivos, con una pérdida mínima de exactitud global. El principal factor limitante es el desbalance del conjunto y el uso exclusivo del sonido; como trabajo futuro, disponer de más grabaciones positivas o incorporar información acústica adicional podría mejorar los resultados. Con ese propósito, la aplicación web desarrollada recolecta nuevas grabaciones con consentimiento. Todo el proyecto emplea una semilla fija ($SEED = 42$) y separa los conjuntos a nivel de paciente, por lo que los resultados

²<https://ml-project-classification.onrender.com>

³<https://erosas-utec.github.io/ml-project-classification/>

Tabla VI
F1 DE LA CLASE POSITIVA (VALIDACIÓN CRUZADA) DE LAS ESTRATEGIAS EXPLORADAS, SOBRE LA SVM RBF

Estrategia	F1
MFCC (40), línea base	0.339
PCA (30 componentes)	0.336
LDA (1 componente)	0.210
Ponderación de clases	0.322
MFCC + deltas (120)	0.233




Figura 3. F1 de la clase positiva en función del umbral de decisión (validación cruzada). El óptimo (0.25) mejora claramente respecto al umbral por defecto 0.5.

son reproducibles. El código fuente completo, incluido el notebook, está disponible en el repositorio público <https://github.com/erosas-utec/ml-project-classification>.

REFERENCIAS

- [1] N. Sharma *et al.*, “Coswara — A database of breathing, cough, and voice sounds for COVID-19 diagnosis,” en *Proc. INTERSPEECH*, 2020, pp. 4811–4815.
- [2] G. Chaudhari *et al.*, “Virufy: Global applicability of crowdsourced and clinical datasets for AI detection of COVID-19 from cough,” *arXiv:2011.13320*, 2020.
- [3] S. Davis y P. Mermelstein, “Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences,” *IEEE Trans. Acoust., Speech, Signal Process.*, vol. 28, n.º 4, pp. 357–366, 1980.
- [4] B. McFee *et al.*, “librosa: Audio and music signal analysis in Python,” en *Proc. 14th Python in Science Conf.*, 2015, pp. 18–25.
- [5] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
- [6] C. Cortes y V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, n.º 3, pp. 273–297, 1995.

Tabla VII
RESULTADOS EN EL CONJUNTO DE PRUEBA (MÉTRICAS DE LA CLASE POSITIVA)

Modelo	Acc	BAcc	Prec	Rec	F1
Línea base (umbral 0.5)	0.879	0.694	0.741	0.417	0.533
Mejorado (umbral 0.25)	0.869	0.721	0.632	0.500	0.558




Figura 4. Matriz de confusión en el conjunto de prueba del modelo mejorado. Cada celda indica el porcentaje respecto a la clase real y, entre paréntesis, el conteo.




Figura 5. Flujo de extracción de características y predicción, idéntico en el entrenamiento y en la inferencia en tiempo real. La aplicación web reutiliza el mismo código, por lo que las predicciones desplegadas coinciden con las del estudio.